Đề cương viết lại

Bộ nhớ liên tưởng dày học từ attractor của chính nó:
trôi từ đặc trưng sang nguyên mẫu

Thiết kế thí nghiệm, đối chứng, và tiêu chí bác bỏ ghi trước

Abstract

Krotov & Hopfield (2016) chỉ ra rằng số mũ tách bạch n quyết định một mạng DAM học ra *đặc trưng* (nét) hay *nguyên mẫu* (chữ số nguyên vẹn) — một vị trí *tĩnh* trên một trục, do siêu tham số đặt, với dữ liệu cố định. Đề cương này đặt câu hỏi mà setting đó không thể hỏi: điều gì xảy ra khi *dữ liệu chính là đầu ra của mạng*? Giả thuyết trung tâm: bộ ký ức khi đó **trôi** dọc đúng trục ấy, luôn về phía nguyên mẫu, và n chỉ quyết định *tốc độ*, không quyết định *đích*. Hệ quả: năng lực là một *giai đoạn quá độ*, tăng khi bộ ký ức còn ở vùng đặc trưng và giảm khi nó ngưng tụ. Chúng tôi đã đo được đúng hình dạng đó trên một hệ spin 150 biến, nơi biết được đáp án đúng; đề cương này chuyển nó sang MNIST — benchmark của chính Krotov — với bốn đối chứng và tiêu chí bác bỏ ghi trước khi chạy.

1 Ghi rõ: cái gì đã có, cái gì là của ta

1.1 Đã có (không phải đóng góp)

1. **DAM và dung lượng.** Krotov & Hopfield (2016): năng lượng $E = -\sum_\mu F(\langle \xi^\mu, v\rangle)$ với $F(x) = \max(x, 0)^n$ cho dung lượng $\sim N^{n-1}$, mũ khi $F = \exp$.
2. **Chuyển tiếp đặc trưng → nguyên mẫu.** Cùng bài, trên MNIST: n thấp thì ký ức học được trông như *nét*; n cao thì trông như *chữ số nguyên vẹn*. Đây là trục khái niệm mà đề cương này dùng.
3. **Attention là truy hồi Hopfield hiện đại.** Ramsauer et al. (2020): năng lượng log-sum-exp cho luật cập nhật đúng bằng softmax attention.
4. **Tự mô hình hoá cải thiện tối ưu hoá.** Watson, Buckley & Mills (2011): mạng Hopfield học Hebb trên attractor của chính nó giải bài ràng buộc tốt hơn.

Phải nói thẳng. Đánh đổi "trừu tượng hoá đổi lấy đa dạng theo n" mà chúng tôi đo được **chính là** chuyển tiếp đặc trưng–nguyên mẫu của Krotov, đo trong hoàn cảnh khác. Bản thân nó *không mới*, và không được trình bày như thể mới.

1.2 Cầu nối là một đồng nhất thức

Lấy self-modeling: các "ký ức" ξ^μ là chính các attractor mà hệ tìm ra. Với $F(x) = x^2$,

$$\sum_\mu \langle \xi^\mu, s\rangle^2 \;=\; s^\top \Big(\sum_\mu \xi^\mu \xi^{\mu\top}\Big) s \;=\; s^\top \Delta W s, \tag{1}$$

đúng bằng luật Hebb của Watson. Nên

$$\boxed{\text{tự mô hình hoá (Watson 2011)} \;=\; \text{DAM tự quy chiếu tại } n = 2.} \tag{2}$$

Không phải ẩn dụ. M1 là *một điểm* trên trục của Krotov, và câu hỏi "ngoài điểm đó thì sao" là câu hỏi chưa ai đặt.

1.3 Giả thuyết trung tâm — cái mới

H. Trong DAM có giám sát, dữ liệu cố định, nên n quyết định mạng *ngồi ở đâu* trên trục đặc trưng–nguyên mẫu, và vị trí đó *tĩnh*. Khi DAM học từ attractor của chính nó, dữ liệu *là* đầu ra của mô hình, nên hệ **di chuyển** dọc trục — luôn về phía nguyên mẫu — và n chỉ đặt *tốc độ*, không đặt *đích*.

Hệ quả H'. Năng lực là giai đoạn quá độ: tăng khi bộ ký ức còn ở vùng đặc trưng, đạt đỉnh, rồi giảm khi ngưng tụ.

Điều này *không thể* nghiên cứu trong setting có giám sát, vì ở đó MNIST không đổi. Vòng phản hồi đơn giản là không tồn tại.

2 Bằng chứng sơ bộ đã có

Trên bài ràng buộc modular $N = 150$ (30 module $\times$ 5 unit), nơi *biết được* lời giải tối ưu ($-483{,}3$) và sàn tìm kiếm cá thể ($-419{,}5$):

n	lợi ích học được	trừu tượng hoá (đỉnh)	đa dạng cuối	hạng hiệu dụng
2	**60**	**2,23**	**1**	290
6	57	1,75	2	259
10	37	1,39	15	94
20	17	1,13	**34**	**4,4**

Table 1: Ba cột đối nghịch đơn điệu. Trên toàn bộ 60 cấu hình (n, γ): corr(đa dạng giữ được, năng lượng cuối) $= +0{,}809$ — giữ được đa dạng thì lời giải tệ đi.

Và tại $n = 2$, quỹ đạo có đúng hình dạng H' dự đoán: trừu tượng hoá lên đỉnh 2,23 rồi rã về 1,03; đa dạng attractor $46 \to 1$; ΔW về *hạng một* ($\lambda_1/\sum\lambda = 0{,}50$, $\cos(\Delta W, ss^\top) = 0{,}90$), tức dung lượng hiệu dụng bằng 1 trong khi Hopfield cổ điển đáng lẽ chứa ≈ 21.

Đây là bằng chứng *gợi ý*, không phải kết quả: một instance bài toán, một họ seed, và "trừu tượng hoá" đo bằng *một* proxy. Nó biện minh cho việc làm thí nghiệm, không thay thế thí nghiệm.

3 Thiết kế thí nghiệm trên MNIST

3.1 Hệ

Ma trận ký ức $\Xi \in \mathbb{R}^{K\times 784}$, năng lượng $E(v) = -\sum_{\mu=1}^{K} F\big(\langle \xi^\mu, v\rangle/\sqrt{N}\big)$, $F(x) = \max(x, 0)^n$. Truy hồi bằng động lực giảm năng lượng.

Vòng tự quy chiếu. Khởi tạo Ξ từ K ảnh MNIST thật — tức *bắt đầu ở vùng đặc trưng/dữ liệu*. Mỗi vòng: lấy một truy vấn (ảnh MNIST nhiễu), thả về attractor a_t, rồi *thay* một ký ức bằng a_t. Lặp.

3.2 Đo gì

1. **Vị trí trên trục đặc trưng–nguyên mẫu.** Với mỗi ký ức ξ^μ, lấy profile tương quan $c_i = \mathrm{corr}(\xi^\mu, x_i)$ với toàn bộ ảnh huấn luyện, rồi tính

$$\mathrm{PR}(\xi^\mu) \;=\; \frac{\big(\sum_i c_i^+\big)^2}{\sum_i (c_i^+)^2}, \qquad c^+ = \max(c, 0). \tag{3}$$

   PR thấp = ký ức giải thích *một* ảnh = nguyên mẫu; PR cao = giải thích *nhiều* ảnh = đặc trưng. Đây là lượng hoá trực tiếp trục của Krotov.

2. **Hạng hiệu dụng** của Ξ (participation ratio của phổ kỳ dị).
3. **Đa dạng**: số attractor phân biệt trong cửa sổ trượt.
4. **Năng lực**: khử nhiễu trên tập giữ lại — làm hỏng một chữ số chưa thấy, thả, rồi chấm bằng *một bộ phân loại ngoài cố định*. Chấm luôn trên nhãn thật, không bao giờ trên năng lượng của mô hình.
5. **Hình ảnh**: hiện chính các ký ức theo thời gian. Nếu H đúng, ở $n = 2$ ta phải *nhìn thấy* chúng nhoè dần về một vệt trung bình.

3.3 Đối chứng — phần đã hỏng ở lần trước

Đây là mục quan trọng nhất của đề cương. Lần trước (ABDAM) thất bại đúng ở đây: một thống kê tổng hợp bị hiểu sai, và cơ chế được tuyên bố không có đối chứng loại trừ lời giải thích tầm thường. Bốn đối chứng dưới đây phải chạy *cùng lúc* với thí nghiệm chính, không phải bổ sung sau.

C1 — không tự quy chiếu (null).
Mỗi vòng thay ký ức bằng một ảnh MNIST *thật*, không phải attractor. *Phải không trôi.* Nếu nó cũng trôi thì hiện tượng không liên quan gì tới tự quy chiếu.

C2 — đổi siêu tham số đơn thuần.
Bất kỳ hiệu ứng nào quan sát được, kiểm xem một thay đổi đơn giản của n hoặc thang năng lượng có tái tạo được không. *Bài học* β: nếu "cơ chế" tương đương một phép đổi thang thì nó không phải cơ chế.

C3 — lưu trữ ngẫu nhiên.
Thay ký ức bằng *vector ngẫu nhiên* cùng chuẩn. Tách "lưu bất cứ thứ gì" khỏi "lưu đầu ra của chính mình". (Trên hệ spin, đối chứng tương ứng đã cho kết quả quyết định: nhiễu đối xứng ngẫu nhiên pha loãng $1{,}00 \to 0{,}77$ và *không* cải thiện gì, trong khi Hebb thật $1{,}00 \to 0{,}11$ và cải thiện 66 đơn vị.)

C4 — có neo.
$\Xi \leftarrow (1-\alpha)\Xi_0 + \alpha\Xi +$ mới. Phải trôi *chậm hơn*, đơn điệu theo α.

3.4 Quy tắc tự vệ, rút từ lần hỏng trước

1. **Mọi thống kê tổng hợp phải kiểm hiện vật.** Trước khi diễn giải một chỉ số bất bình đẳng, tính giá trị của nó cho phân bố *tầm thường* tương ứng. (Gini của "k ô bằng nhau + m ô rỗng" là $1 - k/(k+m)$ — nếu số đo trùng con số đó thì nó không đo tự tổ chức.)
2. **Chạy quá đỉnh.** Không dừng ở epoch mà hiệu năng tốt nhất. Chạy ít nhất $5\times$ thời gian tới đỉnh, để thấy phần sau.
3. **Nhiều seed và nhiều tập con dữ liệu**, báo cáo sai số chuẩn. Một instance không phải kết quả.
4. **Chấm trên đại lượng ngoài.** Không bao giờ dùng năng lượng của chính mô hình làm thước đo năng lực.

4 Tiêu chí bác bỏ — ghi TRƯỚC khi chạy

- **H chết** nếu PR trung bình *không* giảm đơn điệu theo vòng ở bất kỳ n nào trong $\{2, 4, 10, 20\}$; hoặc nếu nó giảm ở n thấp nhưng *tăng* ở n cao (khi đó n quyết định đích, không chỉ tốc độ).
- **H chết** nếu C3 (lưu ngẫu nhiên) cho độ trôi bằng thí nghiệm chính trong sai số 20% — khi đó tự quy chiếu không đóng vai trò gì.
- **H chết** nếu C1 (dữ liệu thật) cũng trôi.
- **H' chết** nếu năng lực khử nhiễu đơn điệu (chỉ tăng, hoặc chỉ giảm), không có đỉnh, trên $\geq 3/4$ số n.
- **Đóng góp bị hạ cấp** nếu mọi hiệu ứng tái tạo được bằng C2.

Nếu H chết mà H' sống, vẫn còn một bài (cửa sổ năng lực trong DAM, đo trên benchmark của Krotov). Nếu cả hai chết thì dừng và không viết gì.

5 Chi phí và rủi ro

Chi phí. MNIST 784 chiều, $K \sim 100$ ký ức, mỗi vòng là vài phép nhân ma trận. Hàng nghìn vòng trong vài phút trên CPU. Toàn bộ lưới $n \times \alpha\times$ seed nằm trong vài giờ. *Không cần GPU.*

Rủi ro, xếp theo mức độ nghiêm trọng.

1. **Hiện tượng có thể tầm thường.** Lưu attractor của chính mình thì attractor được củng cố — có thể ai cũng thấy ngay. Phản biện: nếu tầm thường thì tự mô hình hoá của Watson đã không hoạt động; nội dung định lượng nằm ở *cửa sổ*, ở biên của nó, và ở việc n điều khiển tốc độ chứ không điều khiển đích. Nhưng phải trình bày cho đúng tầm.

2. **Thước đo** PR **có thể không sạch.** Cần kiểm trên các trường hợp đã biết (ảnh thật $\Rightarrow$ PR thấp; ảnh trung bình $\Rightarrow$ PR cao) trước khi tin.

3. **Có thể đã có người làm.** Tìm kiếm sơ bộ không thấy "DAM học từ attractor của chính nó", nhưng chưa vét hết; phải đọc kỹ mảng động lực học của DAM (ví dụ arXiv:2506.00851) trước khi tuyên bố tính mới.

4. **Quy mô.** MNIST với n cao có thể quá dễ, giống như bài toán spin tự tầm thường hoá khi module lớn. Cần kiểm độ khó trước: nếu khử nhiễu đạt trần ngay từ vòng đầu thì không có chỗ cho cửa sổ xuất hiện.

6 Việc cần làm, theo thứ tự

1. Kiểm thước đo PR trên các trường hợp đã biết. Vài phút. Không qua thì dừng.
2. Kiểm độ khó: khử nhiễu có trần không, có chỗ cho cải thiện không.
3. Thí nghiệm chính + bốn đối chứng, chạy đồng thời, $n \in \{2, 4, 10, 20\}$, ≥ 5 seed, chạy quá đỉnh $5\times$.
4. Chỉ khi (3) qua tiêu chí bác bỏ mới viết.

Bằng chứng sơ bộ: `dam_selfmodel.py`, `run_dam_sweep.py`, `data/dam_sweep.npz`. Hệ spin: $N = 150, 30 \times 5$, $p = 0{,}8$, chấm trên A với đường chéo bằng không.